

LAPORAN AUDIT & VALIDASI EKSPERIMEN ML

MEDSIGN

Audit Independen Bukti Empiris, Integritas Data, dan Konsistensi Metrik 8 Eksperimen

STATUS: VERIFIED
(PASS)

Ringkasan Audit: Seluruh 8 eksperimen ML telah diaudit secara statis dan empiris terhadap dataset asli, split holdout, arsitektur model, artefak checkpoint (.keras & .tflite), log terminal, serta laporan klasifikasi. Tidak ditemukan data leakage atau kontaminasi data sintesis pada validation/test set.

1. VERIFIKASI PEMISAHAN MODEL & ARSITEKTUR

ENTITAS VALIDASI	MODEL 1 (CLINICAL WORDS)	MODEL 2 (ALPHABET & NUMBERS)	STATUS AUDIT
Jumlah Kelas Output	200 Kelas Klinis Terlatih	36 Kelas (10 Angka + 26 Huruf)	TERPISAH KETAT (PASS)
Lokasi Dataset	backend/data/landmarks/	backend/data/landmark_abjad_angka/	INDEPENDEN (PASS)
Single 236-Class Classifier	TIDAK ADA	TIDAK ADA	MEMATUHI SYARAT (PASS)
Preprocessing Contract	Frame: 30, Feature: 63, Normalized	Frame: 30, Feature: 63, Normalized	KONSISTEN (PASS)
Isolasi Test Set	Holdout murni (Tanpa Augmentasi)	Holdout murni (Tanpa Augmentasi)	ZERO LEAKAGE (PASS)

2. HASIL AUDIT EMPIRIS — MODEL 1: CLINICAL WORDS (200 KELAS)

ID	ARSITEKTUR	AUGMENTASI	TRAIN ACC	VAL ACC	TEST ACC	MACRO PREC	MACRO REC	MACRO F1	WAKTU	STATUS ARTEFAK
E1	LSTM	NO	68.19%	79.47%	80.53%	80.69%	80.20%	78.38%	21.57s	VERIFIED (100% MATCH)
E2	LSTM	YES	90.22%	90.49%	91.38%	92.03%	91.01%	90.70%	68.5s	VERIFIED (100% MATCH)
E3	GRU	NO	66.03%	78.96%	80.93%	82.35%	80.61%	79.00%	23.82s	VERIFIED (100% MATCH)
E4	GRU	YES	89.99%	89.86%	90.06%	91.22%	89.70%	89.19%	69.64s	VERIFIED (100% MATCH)

3. HASIL AUDIT EMPIRIS — MODEL 2: ALPHABET & NUMBERS (36 KELAS)

ID	ARSITEKTUR	AUGMENTASI	TRAIN ACC	VAL ACC	TEST ACC	MACRO PREC	MACRO REC	MACRO F1	WAKTU	STATUS ARTEFAK
E5	LSTM	NO	65.38%	69.80%	70.24%	67.51%	70.24%	66.44%	10.15s	VERIFIED (100% MATCH)
E6	LSTM	YES	80.40%	81.68%	82.14%	84.00%	82.14%	81.11%	24.04s	VERIFIED (100% MATCH)

ID	ARSITEKTUR	AUGMENTASI	TRAIN ACC	VAL ACC	TEST ACC	MACRO PREC	MACRO REC	MACRO F1	WAKTU	STATUS ARTEFAK
										MATCH)
E7	GRU	NO	69.35%	73.27%	74.60%	76.68%	74.60%	72.36%	13.28s	VERIFIED (100% MATCH)
E8	GRU	YES	86.72%	87.62%	84.92%	85.05%	84.92%	83.70%	24.82s	VERIFIED (100% MATCH)

4. ANALISIS PENINGKATAN AUGMENTASI & PENCEGAHAN OVERFITTING

MODEL & ARSITEKTUR	DELTA TEST ACCURACY	DELTA MACRO F1	EVALUASI OVERFITTING (GENERALIZATION GAP)	STATUS VALIDASI
Clinical: LSTM (E1 vs E2)	+10.85%	+12.32%	Train Acc 90.22% vs Val Acc 90.49% (Gap: -0.27%, Tidak Overfit)	VALID
Clinical: GRU (E3 vs E4)	+9.13%	+10.19%	Train Acc 89.99% vs Val Acc 89.86% (Gap: +0.13%, Sangat Seimbang)	VALID
Alphanumeric: LSTM (E5 vs E6)	+11.90%	+14.67%	Train Acc 80.40% vs Val Acc 81.68% (Gap: -1.28%, Stabil)	VALID
Alphanumeric: GRU (E7 vs E8)	+10.32%	+11.34%	Train Acc 86.72% vs Val Acc 87.62% (Gap: -0.90%, Generalisasi Tinggi)	VALID

5. AUDIT PERFORMA PER KELAS (TOP 10 TERBAIK VS TERBURUK)

CLINICAL WORDS (E2 LSTM AUG)

KATEGORI	DAFTAR KELAS	RATA-RATA F1
Top 10 Best	dokter, periksa, sembuh, resep, pagi, siang, malam, makan, minum, batuk	100.0%
Top 10 Worst	tumbuh, identitas, wali, sepertinya, leher, kaki, sesak, napas, pusing, sedang	26.4%

ALPHABET & NUMBERS (E8 GRU AUG)

KATEGORI	DAFTAR KELAS	RATA-RATA F1
Top 10 Best	0, 2, 3, a, c, e, f, i, j, o	100.0%
Top 10 Worst	6, t, p, 9, h, 5, d, 7, 8, 4	50.7%

Catatan Audit atas Klaim Penyebab (Section 15): Kemiripan gestur antara *sesak* vs *napas* dan *t* vs *p* dikonfirmasi secara matematis melalui matriks konfusi (tingkat misklasifikasi tinggi antar pasangan tersebut), dan diklasifikasikan sebagai **HYPOTHESIS / QUALITATIVE INTERPRETATION** yang didukung data empiris confusion matrix.

6. VERIFIKASI INTEGRITAS DATA & AUTO-ROLLBACK

ASPEK AUDIT INTEGRITAS	BUKTI / HASIL AUDIT	STATUS
Kondisi Direktori Dataset Asli	Direktori asli utuh (Clinical: 202 folder, Alphanumeric: 36 folder)	VERIFIED (UNCHANGED)
Pembersihan Sampel Augmentasi	Mekanisme in-memory staging + try/finally auto-rollback terverifikasi	VERIFIED (CLEAN)
Ketersediaan Checkpoint	8 berkas .keras dan 8 berkas .tflite lengkap di experiments/	VERIFIED (100% PRESENT)
Reproducibility	Seed deterministik (random=42, numpy=42, tf=42, split=42/43)	REPRODUCIBLE (PASS)

KESIMPULAN AUDIT FINAL: PASS (MEMENUHI SELURUH ACCEPTANCE CRITERIA)

Hasil benchmarking 8 eksperimen model ML MedSign (Clinical Words 200 kelas dan Alphabet/Numbers 36 kelas) terbukti **otentik, valid secara metodologi (zero data leakage, holdout test untouched)**, memiliki **checkpoint tersimpan yang dapat digunakan untuk inferensi**, dan didukung artefak metrik lengkap.